Leistungstest KI: Das kann drankommen

Informatik FOS 12 · Informatik 11 · Informatik 12 · Informatik 13 · SJ 2026/27 · 30 Aufgaben

AUFGABEN

1. Welche Grundidee steckt hinter künstlichen neuronalen Netzen?
2. Das Gehirn hat etwa 86 Milliarden Neurone, jedes ist im Schnitt mit 10 000 anderen verbunden. Wie viele Verbindungen („Parameter“) sind das ungefähr?
3. Ein künstliches Neuron bekommt die Eingänge 5 und 2 mit den Gewichten 0,8 und 0,5. Sein Ergebnis geht mit dem Gewicht 0,6 weiter. Was kommt beim nächsten Neuron an?
4. Wann und wo wurde die Künstliche Intelligenz als Forschungsgebiet begründet?
5. Warum „explodiert“ KI gerade jetzt? Nenne die zwei Gründe aus dem Vortrag.
6. Wofür stehen die drei Buchstaben in GPT?
7. Wie heißt der Artikel von 2017, mit dem der Transformer – das T in GPT – vorgestellt wurde?
8. „Gestern war ich beim Italiener … Und ich liebe …“ – warum ergänzt ein Sprachmodell hier „Spaghetti“, in einem Liebesbrief aber „Dich“?
9. Was zeigt das Beispiel der „manipulierten Vorhersage“ („… im Wesentlichen einer Person zu verdanken: Bundeskanzler Merz“)?
10. GPT-3 wurde mit rund 500 Milliarden Token trainiert, heutige Modelle mit 15 bis 30 Billionen. Wie viel Mal so viel ist das?
11. GPT-3 hat 175 Milliarden Parameter, das Gehirn etwa 10^{15} Verbindungen. Wie viel Mal so viele hat das Gehirn?
12. Wie lernte AlphaGo Zero Go – und wie ging es gegen das ältere AlphaGo aus?
13. Was bedeutet „Reasoning“ bei einem Sprachmodell?
14. DeepSeek gab für das Training von DeepSeek-V3 2,788 Millionen GPU-Stunden an, gerechnet mit 2 US-Dollar je Stunde. Was kostete das?
15. Was ist der Unterschied zwischen „Open Weights“ und Open Source?
16. Welche KI-Anwendung ist nach dem EU AI Act seit Februar 2025 in der Schule verboten?
17. Nenne drei Probleme heutiger KI aus dem Vortrag.
18. Warum ist „Ich habe ein Video davon“ heute kein Beweis mehr?
19. Wo steckt nach dem Training, was ein neuronales Netz gelernt hat?
20. Was heißt „Deep Learning“?
21. Wie lernt ein Netz beim Training aus einem Fehler (Backpropagation)?
22. Wofür steht LLM, und welche einzige Aufgabe hat ein LLM?
23. Faustregel Deutsch: 1 Wort ≈ 1,5 bis 2 Token. Mit wie vielen Token rechnest du bei einem Text mit 300 Wörtern?
24. GPT-4 kennt nur 100 256 Token, Deutsch hat aber Millionen Wortformen. Wie passt das zusammen?
25. Was passiert, wenn das Kontextfenster voll ist?
26. 2020 fasste ein Kontextfenster etwa 2 000 Token, 2026 bis zu 1 000 000. Wie viel Mal so groß ist das?

27. Was ist eine Halluzination, und woher kommt sie?
28. Worin unterscheiden sich Prompt Engineering und Context Engineering?
29. Was geschieht bei RAG, bevor das Modell antwortet?
30. Was macht aus einem Sprachmodell einen Agenten?

LÖSUNGEN

1. Welche Grundidee steckt hinter künstlichen neuronalen Netzen?

> „Copy the Brain“: Man baut das Gehirn in seiner wesentlichen Funktion nach – viele einfache Neurone, die über gewichtete Verbindungen Zahlen weitergeben.

2. Das Gehirn hat etwa 86 Milliarden Neurone, jedes ist im Schnitt mit 10 000 anderen verbunden. Wie viele Verbindungen („Parameter“) sind das ungefähr?

> 86 Milliarden mal 10 000: $86 \cdot 10^9 \cdot 10^4 = 86 \cdot 10^{13} = 8{,}6 \cdot 10^{14} \approx 10^{15}$. Das sind rund eine Billiarde Verbindungen.

3. Ein künstliches Neuron bekommt die Eingänge 5 und 2 mit den Gewichten 0,8 und 0,5. Sein Ergebnis geht mit dem Gewicht 0,6 weiter. Was kommt beim nächsten Neuron an?

> Erst jeden Eingang mit seinem Gewicht malnehmen und alles addieren: $5 \cdot 0{,}8 + 2 \cdot 0{,}5 = 4 + 1 = 5$. Dann mit dem nächsten Gewicht malnehmen: $5 \cdot 0{,}6 = 3$. Beim nächsten Neuron kommt 3 an.

4. Wann und wo wurde die Künstliche Intelligenz als Forschungsgebiet begründet?

> 1956 beim Dartmouth Workshop in den USA (Dartmouth Summer Research Project on Artificial Intelligence) – mit Marvin Minsky, Claude Shannon, Ray Solomonoff und anderen.

5. Warum „explodiert“ KI gerade jetzt? Nenne die zwei Gründe aus dem Vortrag.

> 1. Riesige Mengen an Trainingsdaten sind verfügbar, z. B. ImageNet mit 15 Millionen von Hand beschrifteten Bildern. 2. Riesige Rechenleistung ist verfügbar: Grafikkarten (NVIDIA) rechnen die nötigen Matrix-Multiplikationen massenhaft parallel.

6. Wofür stehen die drei Buchstaben in GPT?

> G = Generative (erzeugt Text), P = Pre-trained (vorab an riesigen Textmengen trainiert), T = Transformer (die Bauart des Netzes).

7. Wie heißt der Artikel von 2017, mit dem der Transformer – das T in GPT – vorgestellt wurde?

> „Attention Is All You Need“ von Vaswani und Kollegen (2017). Unsere Präsentation trägt denselben Titel.

8. „Gestern war ich beim Italiener … Und ich liebe …“ – warum ergänzt ein Sprachmodell hier „Spaghetti“, in einem Liebesbrief aber „Dich“?

> Es sagt das wahrscheinlichste nächste Wort voraus, und was wahrscheinlich ist, hängt vom Text davor ab (Prompt bzw. Kontext). Nach dem Italiener passt „Spaghetti“, nach einer Liebeserklärung „Dich“.

9. Was zeigt das Beispiel der „manipulierten Vorhersage“ („… im Wesentlichen einer Person zu verdanken: Bundeskanzler Merz“)?

> Die Vorhersage lässt sich lenken: Das Modell setzt fort, was zu den Mustern im Kontext und in den Trainingsdaten passt – ob es stimmt, prüft es nicht. Wer Prompt oder Trainingsdaten steuert, steuert die Antwort.

10. GPT-3 wurde mit rund 500 Milliarden Token trainiert, heutige Modelle mit 15 bis 30 Billionen. Wie viel Mal so viel ist das?

> 1 Billion = 1 000 Milliarden. Also $15\,000 : 500 = 30$ und $30\,000 : 500 = 60$. Heutige Modelle lernen aus 30- bis 60-mal so viel Text.

11. GPT-3 hat 175 Milliarden Parameter, das Gehirn etwa 10^{15} Verbindungen. Wie viel Mal so viele hat das Gehirn?

> $10^{15} = 1\,000\,000\,000\,000\,000$ geteilt durch $175\,000\,000\,000$. Auf beiden Seiten neun Nullen streichen: $1\,000\,000 : 175 \approx 5\,714$. Das Gehirn hat rund 5 700-mal so viele Verbindungen.

12. Wie lernte AlphaGo Zero Go – und wie ging es gegen das ältere AlphaGo aus?

> AlphaGo Zero ist selbstlernend: Es spielte nur gegen sich selbst. Nach 40 Tagen Training schlug es AlphaGo Lee – die Version, die 2016 Weltmeister Lee Sedol 4 : 1 besiegt hatte – mit 100 : 0.

13. Was bedeutet „Reasoning" bei einem Sprachmodell?

> Das Modell schreibt erst eine interne Gedankenkette und antwortet dann. Es bekommt mehr Rechenzeit beim Antworten statt mehr Parameter beim Training – das hilft vor allem bei Mathematik, Physik und Programmieren.

14. DeepSeek gab für das Training von DeepSeek-V3 2,788 Millionen GPU-Stunden an, gerechnet mit 2 US-Dollar je Stunde. Was kostete das?

> $2{,}788 \cdot 2 = 5{,}576$, also 5,576 Millionen US-Dollar – rund 5,6 Millionen. Achtung: nur die Trainingsläufe, ohne Vorversuche, ohne Hardware und nicht unabhängig geprüft. Trotzdem bebten die Technologie-Börsen.

15. Was ist der Unterschied zwischen „Open Weights" und Open Source?

> Bei Open Weights (z. B. Llama, Mistral, Qwen, DeepSeek) kann man die Gewichte herunterladen und das Modell auf eigener Hardware betreiben – keine Cloud, keine Daten nach draußen. Die Trainingsdaten bleiben aber geheim; echtes Open Source würde alles offenlegen.

16. Welche KI-Anwendung ist nach dem EU AI Act seit Februar 2025 in der Schule verboten?

> Die Emotionserkennung. Der EU AI Act gilt seit August 2024 und ordnet KI nach Risikoklassen: je höher das Risiko, desto strenger die Pflichten. Bildung zählt zu den Hochrisiko-Bereichen.

17. Nenne drei Probleme heutiger KI aus dem Vortrag.

> Zum Beispiel: Halluzinationen (erfundene Antworten); niemand kann sagen, warum das System eine bestimmte Antwort gab; Verzerrung (Bias) durch menschliche Clickworker; riesiger Stromverbrauch (das Gehirn braucht nur 20 Watt); Wissen auf einen Zeitpunkt eingefroren (Websuche und Werkzeuge mildern das); im Extremfall das Aussterben der Menschheit – „this is not a joke!"

18. Warum ist „Ich habe ein Video davon" heute kein Beweis mehr?

> Weil KI aus Text Videos mit Ton erzeugt (Sora von OpenAI, Veo von Google) und Stimmen in Sekunden klont – täuschend echt, Gespräche sogar in Echtzeit.

19. Wo steckt nach dem Training, was ein neuronales Netz gelernt hat?

> Ausschließlich in den Gewichten – den Zahlen an den Verbindungen. Niemand programmiert sie; sie werden aus Beispielen zurechtgerückt, bis der Fehler klein ist.

20. Was heißt „Deep Learning"?

> Lernen mit einem Netz aus vielen Schichten hintereinander. Die verdeckten Schichten bauen Merkmale auf: frühe erkennen Kanten, spätere z. B. Augen, noch spätere Gesichter.

21. Wie lernt ein Netz beim Training aus einem Fehler (Backpropagation)?

> Das Netz rät, vergleicht mit der Lösung und misst den Fehler. Der Fehler läuft rückwärts durchs Netz, und alle Gewichte werden ein kleines Stück in die bessere Richtung gerückt – millionenfach, bis der Fehler klein bleibt.

22. Wofür steht LLM, und welche einzige Aufgabe hat ein LLM?

> Large Language Model, ein großes Sprachmodell. Seine einzige Aufgabe: das nächste Token vorhersagen. Es erzeugt Text (generativ), es schlägt ihn nicht nach.

23. Faustregel Deutsch: 1 Wort ≈ 1,5 bis 2 Token. Mit wie vielen Token rechnest du bei einem Text mit 300 Wörtern?

> $300 \cdot 1{,}5 = 450$ und $300 \cdot 2 = 600$. Also mit etwa 450 bis 600 Token.

24. GPT-4 kennt nur 100 256 Token, Deutsch hat aber Millionen Wortformen. Wie passt das zusammen?

> Der Tokenizer zerlegt Text in Stücke: Häufige Wörter sind ein Token, lange oder seltene zerfallen in Wortteile („Kont|ext|fen|ster“). Aus den Stücken lässt sich jedes Wort zusammensetzen.

25. Was passiert, wenn das Kontextfenster voll ist?

> Das Älteste fällt heraus – das Modell vergisst es. Das Kontextfenster ist sein Kurzzeitgedächtnis: Systemanweisung, Verlauf, Anhänge und auch die Antwort müssen hineinpassen.

26. 2020 fasste ein Kontextfenster etwa 2 000 Token, 2026 bis zu 1 000 000. Wie viel Mal so groß ist das?

> $1\,000\,000 : 2\,000 = 1\,000 : 2 = 500$. Das Fenster ist 500-mal so groß – von etwa 3 Seiten zu einem ganzen Regal. Aber größer ist nicht automatisch besser: Die Mitte wird schlechter beachtet, und jedes Token kostet bei jeder Anfrage neu.

27. Was ist eine Halluzination, und woher kommt sie?

> Das Modell erfindet etwas, das plausibel klingt – oft Quellen, Zitate, Zahlen oder Paragraphen. Ursache: Es sagt das wahrscheinlichste Wort voraus, nicht das wahre, und hat keine „weiß ich nicht“-Taste. Gegenmittel: Beleg mitgeben und nachprüfen.

28. Worin unterscheiden sich Prompt Engineering und Context Engineering?

> Prompt Engineering formuliert die einzelne Anweisung präzise („Wie formuliere ich?“). Context Engineering füllt das ganze Kontextfenster bewusst – Daten, Werkzeuge, Verlauf, Regeln („Was weiß das Modell gerade?“) – und lässt Ballast weg.

29. Was geschieht bei RAG, bevor das Modell antwortet?

> RAG = Retrieval-Augmented Generation: Erst wird im eigenen Bestand gesucht (nach Ähnlichkeit, über Embeddings), dann wandern die Fundstellen in den Prompt. Das Modell antwortet aus dem mitgelieferten Text – aktuell, prüfbar, mit Quelle.

30. Was macht aus einem Sprachmodell einen Agenten?

> Agent = Modell + Werkzeuge + Schleife + Ziel. Er plant, ruft ein Werkzeug auf, prüft das Ergebnis und korrigiert sich – mehrere Schritte ohne Rückfrage. Der Mensch setzt Ziel und Grenzen; das Risiko liegt in den Berechtigungen.