

Aussprache-Erkennung im Sprachtutor

Warum Spracherkennung dafür das falsche Werkzeug ist – und was stattdessen funktioniert.
Anwendungsfall: Chinesisch in Kaimbo.

DOC ALVERS MATHE-LABOR · KONZEPTPAPIER · 05.09.2026

1 DIE BEOBACHTUNG, UM DIE ES GEHT

Beim Diktieren interpretiert das System mit. Nuschelt man ein Wort, ergänzt es aus dem Kontext das Wahrscheinliche. Für Diktat ist das ein Segen – für einen Sprachtutor ist es **genau der Fehler**.

Denn beim Chinesischlernen hängt die Bedeutung an der Aussprache selbst. Wer **ch** retroflex statt palatal spricht oder den dritten Ton nicht absenkt, sagt etwas anderes. Ein Tutor, der freundlich miträt, was gemeint war, meldet dann „richtig“ – und der Lernende übt seinen Fehler ein.

KERNPROBLEM

Whisper und verwandte Modelle enthalten ein Sprachmodell, das Aussprachefehler **repariert**. Sie sind darauf optimiert zu erkennen, was gemeint war, nicht was gesagt wurde. Ein Aussprachetrainer, der auf Whisper-Transkripten aufsetzt, ist deshalb systematisch blind für exakt die Fehler, die er finden soll.

2 DER PERSPEKTIVWECHSEL

Die Lösung ist kein besseres Erkennungsmodell, sondern eine andere Fragestellung. Im Tutor ist der Zielsatz **bekannt** – der Lernende soll ja etwas Bestimmtes nachsprechen. Damit ist das Problem kein Erkennungs-, sondern ein **Abgleichproblem**, und das ist deutlich einfacher und robuster.

Das Standardverfahren dafür heißt **Forced Alignment + GOP** („Goodness of Pronunciation“, Witt & Young 1999) und ist in der computergestützten Aussprachebewertung seit Jahrzehnten etabliert:

1. **Forced Alignment**. Die bekannte Ziel-Lautfolge wird auf das Audio gelegt: Welcher Zeitabschnitt der Aufnahme gehört zu welchem Laut?
2. **Scoring pro Laut**. Für jeden Abschnitt bewertet ein akustisches Modell, wie gut der tatsächliche Klang zum erwarteten Laut passt. Ein niedriger Wert markiert genau die Stelle, an der es hakt.

Der entscheidende Unterschied: Das Ergebnis ist nicht „richtiges Wort / falsches Wort“, sondern eine **Karte über den Satz**, auf der die schwachen Stellen eingezeichnet sind.

3 GIBT ES EINEN SPRECHERÜBERGREIFENDEN FINGERPRINT?

Das ist die eigentliche Frage: Lässt sich „korrekt ausgesprochen“ so beschreiben, dass es unabhängig von der konkreten Stimme gilt? Antwort: **ja** – aber in zwei getrennten Baustellen mit unterschiedlichen Verfahren.

Baustelle A: Töne

Der einfachere und für Chinesisch wichtigste Teil. Absolute Tonhöhen sind wertlos: Eine tiefe Männerstimme liegt in ganz anderen Hertz-Bereichen als eine helle Frauenstimme. Aber:

- Grundfrequenz (F0) über die Silbe messen – Standardverfahren wie YIN, pYIN oder CREPE, im Browser mit Web Audio machbar.
- **Sprechernormierung:** Umrechnen in Halbtöne relativ zum eigenen Median über die Äußerung. Damit fällt die individuelle Stimmlage vollständig heraus.
- Übrig bleibt die **Form der Kontur** – und die ist tatsächlich sprecherunabhängig: Ton 1 hoch und flach, Ton 2 steigend, Ton 3 fallend und wieder steigend, Ton 4 kurz und scharf fallend.

Das ist der gesuchte generische Fingerprint, und er ist erstaunlich robust. Der Vergleich läuft dann als Kurvenabgleich gegen die Zielkontur, wobei unterschiedliche Sprechgeschwindigkeit über eine Zeitverzerrung (DTW) ausgeglichen wird.

FALLE: TON-SANDHI

Töne ändern sich im Satz. Treffen zwei dritte Töne aufeinander, wird der erste zum zweiten Ton. Ausgerechnet **nǐ hǎo** ist so ein Fall: korrekt gesprochen klingt es *ní hǎo*. Ein Tutor, der stur gegen die Wörterbuchtöne prüft, würde die richtige Aussprache als Fehler anstreichen. Die Sandhi-Regeln müssen also vor dem Vergleich auf die Zielkontur angewandt werden – das ist überschaubar, aber man muss es wissen.

Baustelle B: Konsonanten und Vokale

Aufwendiger, aber ebenfalls machbar. Hier hilft, dass die typischen Fehler deutscher Muttersprachler im Chinesischen bekannt und begrenzt sind:

ZIELAUT	TYPISCHER FEHLER	MESSBARES MERKMAL
Pinyin ch , zh , sh (retroflex, Zunge zurückgerollt)	ersetzt durch deutschen bzw. englischen <i>tsch-/sch</i> -Laut	Spektraler Schwerpunkt des Reibegeräuschs – retroflex klingt messbar dunkler
Pinyin q , j , x (palatal)	Verwechslung mit der retroflexen Reihe	Dasselbe Merkmal, andere Richtung – die beiden Reihen trennen sich sauber
Pinyin ü	als <i>u</i> gesprochen	Formantlage (F2), nach Sprecher normiert
Aspirierte vs. unaspirierte Paare (p/b , t/d , k/g)	deutsche Stimmhaftigkeit statt Behauchung	Voice Onset Time – direkt aus dem Signal messbar

Für die allgemeine Variante liefert ein Phonem-CTC-Modell (etwa wav2vec 2.0 mit IPA-Ausgabe) die *tatsächlich* gesprochene Lautfolge – im Gegensatz zu Whisper ohne korrigierendes Sprachmodell. Der Vergleich mit der Ziel-Lautfolge zeigt dann direkt, welcher Laut durch welchen ersetzt wurde.

4 DER WIRKLICH HARTE TEIL: KALIBRIERUNG

Weder Tonkurve noch Lautvergleich sind das eigentliche Risiko. Das Risiko ist die Schwelle: **Ab wann ist „anders“ auch „falsch“?**

- Muttersprachler streuen erheblich – Dialekt, Tempo, Stimmung, Erkältung.
- Eine einzelne Referenzaufnahme als Maßstab ist deshalb untauglich. Es braucht eine **Verteilung** und daraus eine Schwelle.
- Ein Tutor, der bei jedem zweiten korrekten Satz nörgelt, wird nach drei Tagen abgeschaltet. Im Zweifel lieber **zu nachsichtig**: ein übersehener Fehler kostet weniger als ein System, dem man nicht mehr glaubt.

Praktischer Ausweg für den Anfang: gar keine Bewertung ausgeben, sondern nur **darstellen**. Wer seine eigene Tonkurve neben der Zielkontur sieht, braucht kein Urteil – er sieht selbst, dass der dritte Ton nicht absinkt.

5 ERSTER SCHRITT: DIE TONKURVE SICHTBAR MACHEN

KLEINSTER SINNVOLLER PROTOTYP

Ein Wort aufnehmen, F0-Kurve extrahieren, sprechernormieren und zusammen mit der Zielkontur in ein gemeinsames Diagramm zeichnen. Kein Score, keine Blackbox, kein Modell-Download – reines Web Audio plus Canvas. Sofort nützlich und vollständig im Browser lauffähig.

Danach in dieser Reihenfolge weiter:

1. Tonkurven-Darstellung, rein visuell.
2. Ähnlichkeitsmaß gegen die Zielkontur (DTW), zunächst nur als Zahl zum Beobachten – nicht als Urteil an den Lernenden.
3. Schwelle kalibrieren an eigenen Aufnahmen: absichtlich richtig und absichtlich falsch sprechen, Verteilungen ansehen.
4. Erst dann segmentale Bewertung (Konsonanten) über ein Phonemmodell.

6 ANBINDUNG AN KAIMBO

Kaimbo bringt die nötigen Teile bereits mit:

- `js/kaimbo-audio.js` enthält schon einen Recorder (Mikrofon → WAV) samt Wiedergabe – die Aufnahmestrecke muss nicht neu gebaut werden.
- Der Zielsatz steht ohnehin in der Karte. Genau das ist die Voraussetzung für Forced Alignment.
- Die Spaced-Repetition-Leiter (0-1-2-4-7-14-60-180) ist der interessanteste Andockpunkt: Ein Wort, das inhaltlich sitzt, aber **lautlich** wackelt, könnte gezielt als Aussprache-Wiederholung wieder hochkommen – statt als bekannt abgehakt zu werden.

Alles läuft lokal im Browser; Aufnahmen müssen das Gerät nicht verlassen.

7 OFFENE PUNKTE

- Reicht ein reines Pitch-Tracking im Browser, oder braucht es für stimmlose Abschnitte und Knarrstimme ein robusteres Modell (CREPE)?

- Wie kommt die Zielkontur zustande – aus Muttersprachler-Aufnahmen oder aus den idealisierten Tonschemata? Aufnahmen sind realistischer, Schemata sind sofort verfügbar.
- Läuft ein Phonem-CTC-Modell in vertretbarer Größe im Browser (transformers.js), oder braucht Baustelle B einen kleinen Server?
- Wie werden Sandhi-Regeln gepflegt – fest verdrahtet oder pro Karte hinterlegbar?
- Übertragbarkeit: Die Tonlogik ist chinesischespezifisch, die segmentale Bewertung wäre auch für Italienisch und Spanisch nutzbar, die in Kaimbo bereits gepflegt sind.

Doc Alvers Mathe-Labor · Aussprache-Tutor · Konzept 05.09.2026